

Data Entrega: 09/09/2026

1 Problema 1

Um artigo em *Cancer Epidemiology, Biomarkers and Prevention* (1996, Vol. 5, pp. 849-852) conduziu um estudo piloto para avaliar o uso de concentrações de arsênio em unhas do dedo do pé, como um indicador de ingestão de água contendo arsênio. Vinte e um participantes foram entrevistados em relação ao uso de seus poços privados (não regulamentados) de água para beber e cozinhar; cada um forneceu uma amostra de água e pedaços de unha do pé. A tabela a seguir mostra os dados de idade (anos), sexo da pessoa (1 = masculino, 2 = feminino), proporção de vezes que o poço da casa foi usado para água de beber ($1 \leq 1/4$, $2 = 1/4$, $3 = 1/2$, $4 = 3/4$, $5 \geq 3/4$), proporção de vezes que o poço da casa foi usado para água de cozinhar ($1 \leq 1/4$, $2 = 1/4$, $3 = 1/2$, $4 = 3/4$, $5 \geq 3/4$), arsênio (ppm) em água e arsênio (ppm) nas unhas dos pés, respectivamente.

- (a) Ajuste um modelo de regressão linear múltipla usando a concentração de arsênio nas unhas como a resposta, e idade, uso para beber, uso para cozinhar e arsênio na água como os regressores.
- (b) Use o modelo para prever o arsênio nas unhas, quando a idade for 30, a categoria da água para beber for 5, a categoria da água para cozinhar for 5 e o arsênio na água for 0,135 ppm.
- (d) Qual é o valor de R^2 score para esse modelo?
- (e) Muitos usuários de regressão preferem usar uma estatística de valor ajustado de R^2 . Por quê? Ela foi melhor que R^2 comum? Se sim, por quê?
- (f) Compare este modelo com um modelo alternativo que use apenas a concentração de arsênio na água como preditor. Qual modelo é melhor? Por que?
- (f) Realize uma análise de resíduos para verificar as suposições do modelo de regressão. Para isso, siga os seguintes passos:

(a) Calcule os valores ajustados para todas as observações de y :

$$\hat{y}_i = \text{valor ajustado pelo modelo}$$

(b) Calcule os resíduos correspondentes:

$$e_i = y_i - \hat{y}_i$$

(c) Organize os resultados em uma tabela mostrando, para cada observação:

- Valor observado: y_i
- Valor ajustado: $\hat{y}_i$
- Resíduo: e_i

Exemplo de Tabela de Resíduos

Observação i	Valor observado y_i	Valor ajustado $\hat{y}_i$	Resíduo e_i
1	10	9.5	0.5
2	12	11.8	0.2
3	9	9.2	-0.2
4	15	14.7	0.3
5	8	8.5	-0.5

Tabela 1: Resíduos para cada observação de y

(Faça uma tabela mostrando os resíduos para todas as observações de y).

- (g) Cenário com Intercepto Forçado a Zero: Suponha que, por razões teóricas, você imponha a restrição de que o intercepto deve ser zero. Qual é a interpretação prática dessa decisão? Compare as métricas R^2 e RMSE deste modelo com o modelo com intercepto. Qual você escolheria e por quê?
- (h) Além do R^2 : Calcule e interprete pelo menos outras duas métricas de erro para o modelo completo e para o modelo alternativo (apenas com Arsênio na água). Sugestões: Erro Quadrático Médio (MSE), Raiz do Erro Quadrático Médio (RMSE) e Erro Absoluto Médio (MAE).

2 Problema 2

Um artigo publicado em *Electronic Packaging and Production* (2002, Vol. 42) considerou o efeito da inspeção de raios X em circuitos integrados. As doses de radiação (expressas em rad, *radiation absorbed dose*) foram estudadas em função da corrente (em miliamperes) e do tempo (em minutos) de exposição.

O Dataset 2 apresenta:

- Dose de Radiação (resposta)
 - Corrente (mAmp)
 - Tempo de Exposição
- (a) Ajuste um modelo de regressão linear múltipla a esses dados, com dose de radiação como variável resposta.
- (b) Use o modelo para prever a dose de radiação quando a corrente for de 15 miliamperes e o tempo de exposição for de 5 minutos.
- (c) Qual é o valor de R^2 score para esse modelo?

- (d) Muitos usuários de regressão preferem usar uma estatística de valor ajustado de R^2 . Por quê? Ela foi melhor que R^2 comum? Se sim, por quê?
- (e) Compare este modelo com um modelo alternativo que use apenas a Corrente como preditor. Qual modelo é melhor? Por que?
- (f) Cenário com Intercepto Forçado a Zero: Suponha que, por razões teóricas, você imponha a restrição de que o intercepto deve ser zero. Qual é a interpretação prática dessa decisão? Compare as métricas R^2 e RMSE deste modelo com o modelo com intercepto. Qual você escolheria e por quê?
- (h) Além do R^2 : Calcule e interprete pelo menos outras duas métricas de erro para o modelo completo e para o modelo alternativo (apenas com Corrente). Sugestões: Erro Quadrático Médio (MSE), Raiz do Erro Quadrático Médio (RMSE) e Erro Absoluto Médio (MAE).

3 Datasets

Dataset - Problema 1: **arseniodataset.csv** disponibilizado na plataforma AVA.

Dataset - Problema 2: **dose_radiacao_expandida.csv** disponibilizado na plataforma AVA.

4 Regras

Métricas de Avaliação de Modelos

Coeficiente de Determinação (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

onde:

- y_i são os valores observados,
- $\hat{y}_i$ são os valores preditos,
- $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ é a média dos valores observados,
- n é o número de observações.

Coeficiente de Determinação Ajustado (R_{adj}^2)

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

onde:

- n é o número de observações,
- p é o número de variáveis independentes (sem contar o intercepto).

Root Mean Squared Error (RMSE)

Quanto menor, mais próximas as previsões estão dos valores reais.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Mean Absolute Error (MAE)

Quanto menor, mais próximas as previsões estão dos valores reais.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

5 Relatório

- **Introdução**

Apresente o tema do relatório, o objetivo das análises para o uso de modelos de regressão. Explique brevemente o objetivo do trabalho.

- **Fundamentação Teórica**

Explique os conceitos principais:

- Regressão linear simples — relação entre uma variável dependente e uma independente.
- Regressão linear múltipla — uso de várias variáveis independentes para explicar a dependente.
- Interpretação dos coeficientes, intercepto, e métricas de avaliação (R^2 , RMSE, MAE).

Use exemplos simples, por exemplo: "Se aumentamos a idade em 1 ano, espera-se que o arsênio nas unhas aumente em X ppm, mantendo as outras variáveis constantes."

- **Protocolo Experimental**

Descreva os dados usados e o procedimento para ajustar o modelo:

- Fonte dos dados.
- Variáveis incluídas no modelo.
- Ferramentas utilizadas (ex: Python, Numpy).
- Passos para ajuste do modelo (ex: verificação de suposições, escolha do modelo).

- **Resultados e Discussão**

Apresente os resultados obtidos, com tabelas e gráficos, e discuta cada um:

- Coeficientes estimados e suas interpretações.
- Previsões para casos específicos.
- Avaliação do modelo usando métricas (R^2 , R^2 ajustado, RMSE, MAE).
- Comparação com modelos alternativos (ex: modelo apenas com Corrente).

- **Conclusão**

Resuma os principais achados, ressalte a importância do modelo para prever exposição ao arsênio e indique possíveis melhorias ou próximos passos.

Observações importantes

- A entrega das implementações é obrigatória. Equipes que não entregarem receberão nota zero.
- A pontualidade é um critério avaliativo.
- Os trabalhos serão submetidos a softwares de detecção de plágio, incluindo IA (ChatGPT, Deep Seek, etc.). Qualquer caso de plágio resultará em nota zero para as equipes envolvidas.
- Não é permitido o uso de bibliotecas com implementações prontas dos modelos exigidos, como o `sklearn` e `pandas`.